UNIVERSIDADE FEDERAL DE SÃO CARLOS
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

SISTEMAS DE BANCOS DE DADOS
Profa. Dra. Sahudy Montenegro González

Entrega Intermediária
Descrição do minimundo + MER + Modelo Relacional + script de criação SQL + Consultas
Data de entrega: 05/07/2024

GRUPO 2
TEMA - **Empresa de Transportes**

Ana Beatriz Juvencio **801817**
Nícolas Benitiz **813037**

Sorocaba
2024

ÍNDICE

No centro econômico de Novo Horizonte, uma nova e promissora empresa de transporte, "Viação Estrelar", está prestes a lançar suas operações. Sob a administração do dinâmico empreendedor João Carvalho, que traz uma vasta experiência do setor de logística da capital, a empresa tem como missão revolucionar o transporte, oferecendo uma solução eficaz e confortável para os deslocamentos diários dos cidadãos e visitantes.

"Viação Estrelar" será especializada no gerenciamento de uma frota moderna de veículos e na organização de rotas otimizadas para maximizar a cobertura e minimizar os tempos de viagem. O sistema desenvolvido permitirá aos clientes comprar passagens e selecionar assentos com facilidade através de uma interface amigável.

No sistema de dados da "Viação Estrelar", encontra-se a tabela de Clientes, que armazena informações essenciais como CPF, nome, endereço, telefone e email. Esta tabela é fundamental para garantir um serviço personalizado e eficaz. A tabela de Horário registra os horários de chegada e partida dos veículos, elemento crucial para a organização dos itinerários.

Cada cidade atendida pela empresa é registrada na tabela Cidade, que especifica os pontos de origem e destino para as rotas. A tabela de Rotas lista todas as rotas disponíveis, incluindo detalhes como distância e preço, proporcionando transparência e opções para os planejamentos de viagem dos clientes.

Os detalhes da frota são gerenciados na tabela de Veículos, que inclui informações como modelo, ano, status operacional e capacidade. Essa gestão cuidadosa garante a eficiência da manutenção e operação dos veículos.

1. Consultas

   Segue as consultas que cada membro ficou responsável:

   1) Quais clientes compraram passagens entre os dias X e Y, desde que o nome do cliente comece com certas letras?

      SELECT Cliente.*

      FROM Cliente

      JOIN Compra ON Cliente.CPF = Compra.CPF

      WHERE Cliente.Nome ILIKE ‘<letras>%’

      AND data_hora_partida BETWEEN ‘X’ AND ‘Y’

      ORDER BY nome;

   2) Quais pessoas compraram passagem com destino à cidade X no dia Y?

```
SELECT Cliente.*

FROM Compra

JOIN Cliente ON Cliente.CPF = Compra.CPF

WHERE Compra.Nome_Cidade_Destino = ‘X’ AND
DATE(Compra.Data_Hora_Chegada) = 'YYYY-MM-DD';
```

2. Projeto Conceitual

2.1. Modelo Entidade-Relacionamento

O DER (Figura 1) representa graficamente as tipo-entidades que compõem o Empresa de Transporte, assim como seus atributos e os tipo-relacionamentos envolvidos, facilitando a compreensão do minimundo e do banco de dados. Acesse: Link

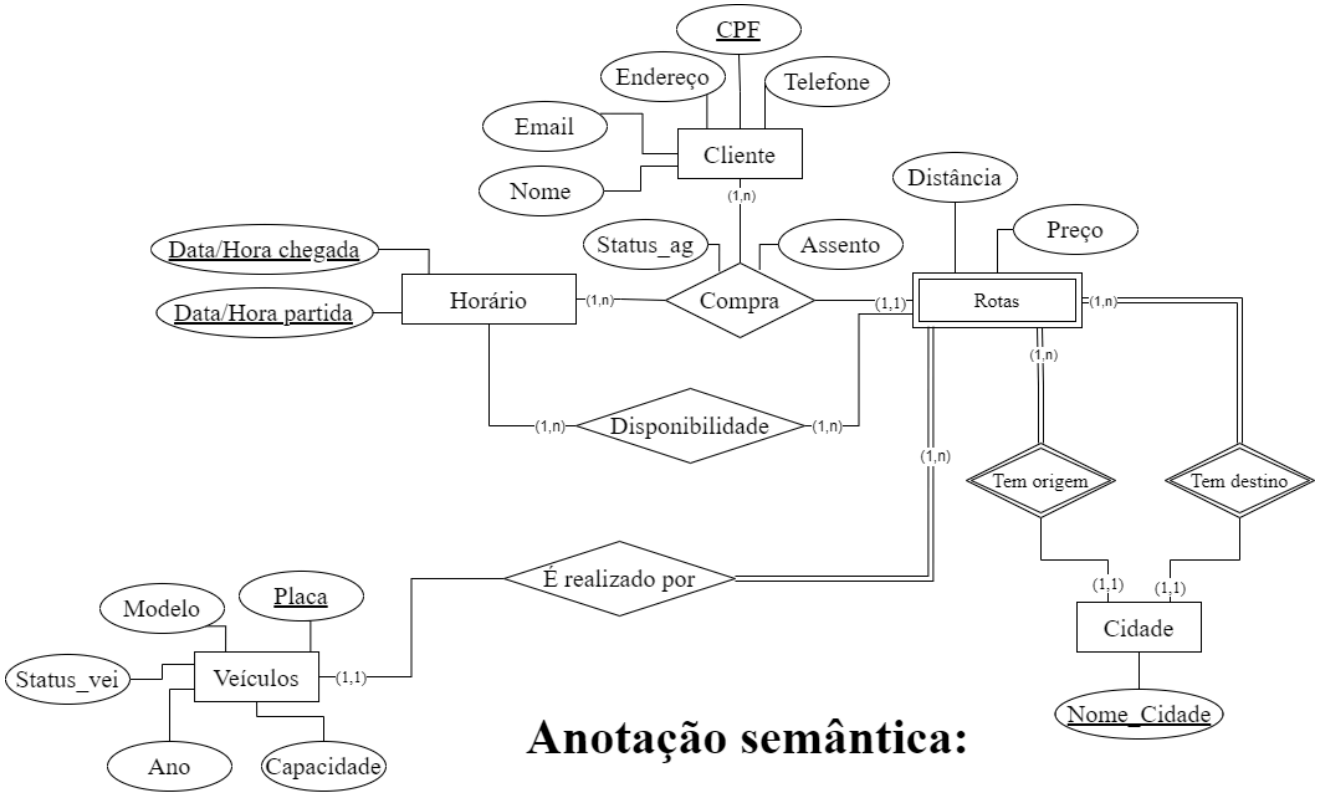

Anotação semântica:

Status_ag: (confirmado, cancelado, realizado)

Status_vei: (disponível, em manutenção)

Não é possível cadastrar uma rota+horario no ternario que nao esteja na disponibilidade

3. Projeto Lógico

Cliente (CPF, Nome, Endereco, Telefone, Email)

Cidade(Nome_Cidade)

Veiculos(Placa, Modelo, Ano, Status_vei, Capacidade)

Rotas(Nome_Cidade_Origem, Nome_Cidade_Destino, Distância, Preco, Placa)

Nome_Cidade_Origem, Nome_Cidade_Destino referencia Cidade

Placa referencia Veiculos

Horario(Data/Hora_Chegada, Data_Hora_Partida)

Disponibilidade(Data/Hora_Chegada,Data_Hora_Partida,Nome_Cidade_Origem, Nome_Cidade_Destino)

data_hora_Chegada ,data_hora_Partida referencia Horario

Nome_Cidade_Origem ,Nome_Cidade_Destino referencia Rotas

Compra(CPF,Data/Hora_Chegada,Data_Hora_Partida,Nome_Cidade_Origem, Nome_Cidade_Destino, Status_ag, Assento)

data_hora_Chegada, data_hora_Partida referencia Horário

Nome_Cidade_Origem, Nome_Cidade_Destino referencia Rotas

CPF referencia Cliente

4. Script para criação do Banco

```
--criando o bd
CREATE DATABASE empresa_de_transportes;

-- Criação da tabela Cliente
CREATE TABLE Cliente (
    CPF VARCHAR(11) PRIMARY KEY,
    Nome VARCHAR(255) NOT NULL,
    Endereco VARCHAR(255) NOT NULL,
    Telefone VARCHAR(20) NOT NULL,
    Email VARCHAR(100) NOT NULL
);

-- Criação da tabela Cidade
CREATE TABLE Cidade (
    Nome_Cidade VARCHAR(100),
    PRIMARY KEY (Nome_Cidade)
);

-- Criação da tabela Horario
CREATE TABLE Horario (
    Data_Hora_Chegada TIMESTAMP WITHOUT TIME ZONE,
    Data_Hora_Partida TIMESTAMP WITHOUT TIME ZONE,
    PRIMARY KEY (Data_Hora_Chegada, Data_Hora_Partida)
);

-- Criação da tabela Veiculos
CREATE TABLE Veiculos (
    Placa VARCHAR(10) PRIMARY KEY,
    Modelo VARCHAR(50) NOT NULL,
    Ano INT NOT NULL,
         Status_vei  VARCHAR(20)  CHECK  (Status_vei  IN  ('disponivel',  'em
manutencao')) NOT NULL,
    Capacidade INT NOT NULL
);

-- Criação da tabela Rotas
CREATE TABLE Rotas (
    Nome_Cidade_Origem VARCHAR(100),
    Nome_Cidade_Destino VARCHAR(100),
    Distancia DECIMAL(10,2) NOT NULL,
    Preco DECIMAL(10,2) NOT NULL ,
    Placa VARCHAR(10),
```

```
    FOREIGN KEY (Placa) REFERENCES Veiculos (Placa),
    FOREIGN KEY (Nome_Cidade_Origem) REFERENCES Cidade(Nome_Cidade),
    FOREIGN KEY (Nome_Cidade_Destino) REFERENCES Cidade(Nome_Cidade),
    PRIMARY KEY (Nome_Cidade_Origem, Nome_Cidade_Destino),
      CHECK (Nome_Cidade_Origem <> Nome_Cidade_Destino) -- Restrição de
verificação
);

-- Criação da tabela Compra
CREATE TABLE Compra (
    CPF VARCHAR(11),
    Data_Hora_Chegada TIMESTAMP WITHOUT TIME ZONE,
    Data_Hora_Partida TIMESTAMP WITHOUT TIME ZONE,
    Nome_Cidade_Origem VARCHAR(100),
    Nome_Cidade_Destino VARCHAR(100),
    Assento INT NOT NULL,
      Status_ag VARCHAR(20) CHECK (Status_ag IN ('confirmado', 'cancelado',
'realizado')) NOT NULL,
    FOREIGN KEY (CPF) REFERENCES Cliente(CPF),
          FOREIGN KEY (Data_Hora_Chegada, Data_Hora_Partida) REFERENCES
Horario(Data_Hora_Chegada, Data_Hora_Partida),
         FOREIGN KEY (Nome_Cidade_Origem, Nome_Cidade_Destino) REFERENCES
Rotas(Nome_Cidade_Origem, Nome_Cidade_Destino),
    PRIMARY KEY (CPF, Data_Hora_Chegada, Data_Hora_Partida)
);


-- Criação da tabela Disponibilidade
CREATE TABLE Disponibilidade (
    Data_Hora_Chegada TIMESTAMP WITHOUT TIME ZONE,
    Data_Hora_Partida TIMESTAMP WITHOUT TIME ZONE,
    Nome_Cidade_Origem VARCHAR(100),
    Nome_Cidade_Destino VARCHAR(100),
          FOREIGN KEY (Data_Hora_Chegada, Data_Hora_Partida) REFERENCES
Horario(Data_Hora_Chegada, Data_Hora_Partida),
         FOREIGN KEY (Nome_Cidade_Origem, Nome_Cidade_Destino) REFERENCES
Rotas(Nome_Cidade_Origem, Nome_Cidade_Destino),
     PRIMARY KEY (Nome_Cidade_Origem, Nome_Cidade_Destino, Data_Hora_Chegada,
Data_Hora_Partida)
);
```

5. Perfil dos usuários
    a. O primeiro tipo de usuário será o cliente, que deseja poder comprar passagens
    b. O segundo será o gerente, que fará o controle da quantidade de passagens que estão sendo compradas para cada destino, horário etc
    c. A terceira será o funcionário da cidade, que deseja saber a quantidade de ônibus que chegam e saem da cidade todos os dias

6. Otimização de Consultas

6.1. Consulta de busca relativa (Nícolas):

Nesta etapa, a consulta relativa inicial será otimizada utilizando algumas estratégias de otimização de consultas. A versão do PostgreSQL utilizada foi a 16.2. Abaixo, apresentamos um resumo das especificações do computador utilizado para os testes:

- **Processador (CPU)**: Intel Core i5 de 10ª geração.
- **Memória RAM**: 8 GB.
- **Armazenamento**: SSD PCIe NVMe de 512 GB.
- **Tipo de Memória Persistente**: SSD (Solid State Drive) para armazenamento.
- **Versão do PostgreSQL:** 16.2
- **Número de amostragem:** 5

(a) Consulta inicial:

```
SELECT Cliente.*

FROM Cliente

JOIN Compra ON Cliente.CPF = Compra.CPF

WHERE Cliente.Nome ILIKE ‘<letras>%’

AND data_hora_partida BETWEEN ‘X’ AND ‘Y’

ORDER BY nome;
```

Para a consulta inicial, temos a execução em segundo indicada pela tabela 1.

Tempo (s)
0.613
0.517
0.497
0.483
0.634

Tabela 1: Tempo de execução da consulta inicial em segundos

(b) Consulta otimizada:

```
SELECT Cliente.*
FROM Cliente

WHERE Cliente.Nome ILIKE ‘<letras>%’

AND Cliente.CPF IN (SELECT Compra.CPF FROM Compra WHERE data_hora_partida BETWEEN 'X' AND ‘Y’')

ORDER BY nome;
```

A fim de otimizar a consulta, eliminou-se a junção explícita e substituiu a mesma por uma subconsulta IN. A subconsulta busca CPF em Compra dentro do intervalo de tempo especificado. Além disso, a consulta otimizada aplica filtros na subconsulta, garantindo que apenas os CPF relevantes sejam considerados antes de realizar a filtragem na tabela Cliente. Os resultados de tais melhorias gerou o tempo de execução da tabela 2. Além disso, a tabela 3 reúne a média de tempos de ambas a consulta e a performance em porcentagem.

Tempo (s)
0.077
0.148
0.127
0.097
0.180

Tabela 2: Tempo de execução da consulta otimizada em segundos

	Consulta Inicial	Consulta Otimizada	Diferença (%)
Tempo de execução	0.5488	0.1258	77.07

Tabela 3. Resumo dos Resultado. Fórmula para cálculo do % = ((Vot - Vini)/Vini × 100)

(c) Plano de consulta inicial:

	QUERY PLAN text
1	Gather Merge (cost=29833.89..40575.44 rows=92064 width=198) (actual time=376.635..421.490 rows=108498 loops=1)
2	Workers Planned: 2
3	Workers Launched: 2
4	-> Sort (cost=28833.86..28948.94 rows=46032 width=198) (actual time=320.947..335.867 rows=36166 loops=3)
5	Sort Key: cliente.nome
6	Sort Method: external merge Disk: 9592kB
7	Worker 0: Sort Method: external merge Disk: 6840kB
8	Worker 1: Sort Method: external merge Disk: 6800kB
9	-> Hash Join (cost=342.89..20862.10 rows=46032 width=198) (actual time=3.303..159.115 rows=36166 loops=3)
10	Hash Cond: ((compra.cpf)::text = (cliente.cpf)::text)
11	-> Parallel Seq Scan on compra (cost=0.00..19431.15 rows=414328 width=69) (actual time=0.342..87.003 rows=331528 loops=3)
12	Filter: ((data_hora_partida >= '2024-01-30 00:00:00'::timestamp without time zone) AND (data_hora_partida <= '2024-12-29 00:00:00'::timestamp without time
13	-> Hash (cost=329.00..329.00 rows=1111 width=129) (actual time=2.796..2.797 rows=1093 loops=3)
14	Buckets: 2048 Batches: 1 Memory Usage: 193kB
15	-> Seq Scan on cliente (cost=0.00..329.00 rows=1111 width=129) (actual time=0.379..2.468 rows=1093 loops=3)
16	Filter: ((nome)::text ~~ 'A%'::text)
17	Rows Removed by Filter: 8907
18	Planning Time: 1.702 ms
19	Execution Time: 427.263 ms

Figura 1: Plano de consulta inicial

Este plano de consulta executa uma varredura sequencial na tabela cliente, filtrando por nomes que começam com a letra 'A' (linhas 15 e 16), seguido pela criação de uma tabela hash com os resultados (linha 13). Posteriormente, é realizada uma junção hash entre as tabelas compra e cliente, onde ambas são escaneadas sequencialmente (linha 14). A consulta utiliza paralelismo, com dois trabalhadores planejados e lançados (linhas 2 e 3). Após a junção hash, os dados são ordenados e mesclados (linhas 10 a 4). Por fim, é realizada uma operação de sort para ordenar os clientes pelo nome (linha 5).

(d) Plano de consulta otimizado:

```
5  EXPLAIN ANALYSE
6  SELECT Cliente.*
7  FROM Cliente
8  WHERE Cliente.Nome ILIKE 'A%'
9  AND Cliente.CPF IN (SELECT Compra.CPF FROM Compra WHERE data_hora_partida BETWEEN '2024-01-30' AND '2024-12-29')
10 ORDER BY nome;
```

Data Output | Messages | Notifications

	QUERY PLAN text
1	Sort (cost=1009.69..1012.47 rows=1111 width=129) (actual time=24.614..24.647 rows=1093 loops=1)
2	Sort Key: cliente.nome
3	Sort Method: quicksort Memory: 220kB
4	-> Nested Loop Semi Join (cost=0.42..953.48 rows=1111 width=129) (actual time=0.071..21.835 rows=1093 loops=1)
5	-> Seq Scan on cliente (cost=0.00..329.00 rows=1111 width=129) (actual time=0.028..8.875 rows=1093 loops=1)
6	Filter: ((nome)::text ~~* 'A%'::text)
7	Rows Removed by Filter: 8907
8	-> Index Only Scan using compra_pkey on compra (cost=0.42..6.32 rows=99 width=11) (actual time=0.011..0.011 rows=1 loops=1093)
9	Index Cond: ((cpf = (cliente.cpf)::text) AND (data_hora_partida >= '2024-01-30 00:00:00'::timestamp without time zone) AND (data_hora_partida <= '2024-12-29 00:00:00'::timestamp without time ...
10	Heap Fetches: 0
11	Planning Time: 0.453 ms
12	Execution Time: 24.714 ms

Figura 2: Plano de consulta otimizado

O consulta otimizado utiliza uma varredura sequencial na tabela cliente filtrando por nomes que começam com a letra 'A', seguido por um Nested Loop Semi Join com a tabela compra usando um índice (linhas 5 e 8), o que é mais eficiente do que a junção hash completa usada anteriormente. A utilização de um Index Only Scan na tabela compra melhora a performance, pois evita leituras desnecessárias no heap, resultando em menor tempo de execução, como pode ser observado na tabela 3.

6.2. Consulta de busca relativa (Ana):

Nesta etapa, realizaremos a otimização da consulta:

```
EXPLAIN ANALYSE SELECT Cliente.*
FROM Compra
JOIN Cliente ON Cliente.CPF = Compra.CPF
WHERE Compra.Nome_Cidade_Destino = 'Recife' AND
DATE(Compra.Data_Hora_Chegada) = '2024-08-04';
```

Segue as informações necessárias do notebook e do PostgreSQL:

- **Processador (CPU)**: Intel Core i7 8º geração.
- **Memória RAM**: 8 GB.
- **Armazenamento**: SSD 240 GB no disco C.
- **Tipo de Memória Persistente**: SSD disco C.
- **Versão do PostgreSQL:** 16
- **Número de amostragem:** 5

a) Segue o Query Plain da consulta 2 não otimizada:

	QUERY PLAN text
1	Nested Loop (cost=1000.28..21485.43 rows=1 width=129) (actual time=7.528..282.650 rows=13 loops=1)
2	-> Gather (cost=1000.00..21477.12 rows=1 width=11) (actual time=7.366..281.874 rows=13 loops=1)
3	Workers Planned: 2
4	Workers Launched: 2
5	-> Parallel Seq Scan on compra (cost=0.00..20477.02 rows=1 width=11) (actual time=80.226..235.470 rows=4 loops=...
6	Filter: (((nome_cidade_destino)::text = 'Recife'::text) AND (date(data_hora_chegada) = '2024-08-04'::date))
7	Rows Removed by Filter: 331524
8	-> Index Scan using cliente_pkey on cliente (cost=0.29..8.30 rows=1 width=129) (actual time=0.055..0.055 rows=1 loops...
9	Index Cond: ((cpf)::text = (compra.cpf)::text)
10	Planning Time: 4.000 ms
11	Execution Time: 283.296 ms

A operação de Nested Loop indica que o PostgreSQL está usando um loop aninhado para combinar as tabelas Compra e Cliente. Com 1000.28 que é o custo inicial e 21485.43 é o custo total estimado. O número estimado de linhas que a operação retornará é de 1 linha estimada, sendo a largura média das linhas retornadas (em bytes), de 129. O tempo real gasto nesta operação foi de 7.528 ms e terminando em 282.650 ms. Foi retornado um total de 13 linhas. E a operação foi executada apenas uma vez.
O Gather reúne os resultados de várias execuções paralelas, com 2 trabalhadores planejados e realmente iniciados, com um total de 13 linhas retornadas e um custo estimado de 1000.00..21477.12. Foi realizada também uma leitura sequencial paralela na tabela Compra, com o tempo real gasto de 80.226..235.470, com as condições do WHERE aplicadas como filtro. Pela minha surpresa, o otimizador decidiu utilizar um index, a chave primária cliente_pkey na tabela Cliente.Com custo estimado da operação de leitura de 0.29..8.30, tempo real gasto: 0.055..0.055 e condições de índice aplicadas:(cpf)::text = (compra.cpf)::text), ou seja, recupera os registros correspondentes com base no campo CPF. Tempo de execução: 283.296 ms.

Tempo (s)
0,283
0,267
0,255
0,243
0,243

Tabela 4: Tempo de execução da consulta inicial em segundos

b) Segue a consulta e o Query Plain da consulta 2 otimizada:

```sql
CREATE INDEX idx_compra_cidade_data ON compra (nome_cidade_destino,
data_hora_chegada);

EXPLAIN ANALYSE SELECT Cliente.*
FROM Compra
JOIN Cliente ON Cliente.CPF = Compra.CPF
WHERE Compra.Nome_Cidade_Destino = 'Recife' AND Data_Hora_Chegada >=
'2024-08-04 00:00:00'
    AND Data_Hora_Chegada < '2024-08-05 00:00:00';
```

Modificamos a consulta tirando o operador DATE(), pois ele adiciona uma complexidade maior, com ele, é preciso converter cada linha de Timestamp para Date e só depois comparar com a data que colocamos no WHERE. E para facilitar ainda mais nossa consulta, criamos um índice composto, pois o índice pode ser usado para encontrar rapidamente todas as linhas que atendem à condição da cláusula WHERE.

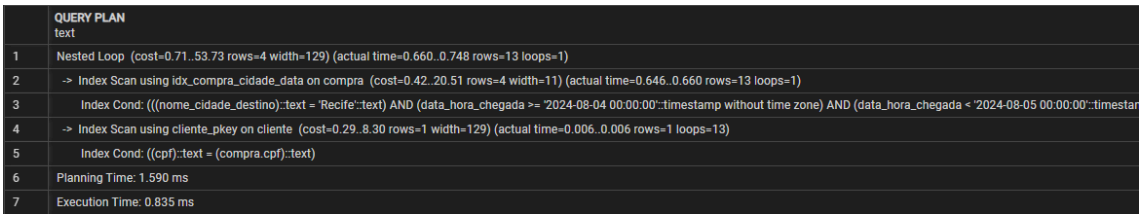

	QUERY PLAN text
1	Nested Loop (cost=0.71..53.73 rows=4 width=129) (actual time=0.660..0.748 rows=13 loops=1)
2	-> Index Scan using idx_compra_cidade_data on compra (cost=0.42..20.51 rows=4 width=11) (actual time=0.646..0.660 rows=13 loops=1)
3	Index Cond: (((nome_cidade_destino)::text = 'Recife'::text) AND (data_hora_chegada >= '2024-08-04 00:00:00'::timestamp without time zone) AND (data_hora_chegada < '2024-08-05 00:00:00'::timestar
4	-> Index Scan using cliente_pkey on cliente (cost=0.29..8.30 rows=1 width=129) (actual time=0.006..0.006 rows=1 loops=13)
5	Index Cond: ((cpf)::text = (compra.cpf)::text)
6	Planning Time: 1.590 ms
7	Execution Time: 0.835 ms

Foi utilizado o Nested Loop Join que é um método de junção onde para cada linha da tabela externa, o banco de dados procura correspondências na tabela interna.
O numero de linhas estimadas é de 4, e linhas reais 13. A largura de 129 que é uma média (em bytes) de cada linha produzida.
O banco de dados está usando um índice (idx_compra_cidade_data) para acessar as linhas da tabela compra. Aqui, a largura foi de 11, custo 0.42..2051, 4 linhas planejadas e 13 retornadas e foram aplicados a condições do WHERE.
O banco também está usando um índice (cliente_pkey) para acessar as linhas da tabela cliente. Foi criado automaticamente pelo PostgreSQL quando definimos a coluna como chave primária.

Tempo (s)
0,000835
0,000227
0,000183
0,000195

0,000196

Tabela 5: Tempo de execução da consulta inicial em segundos

	Consulta Inicial	Consulta Otimizada	Diferença (%)
Tempo de execução	258,2 ms	0,3272 ms	99,80%

Tabela 6. Resumo dos Resultado. Fórmula para cálculo do % = ((Vot - Vini)/Vini × 100)